

深度学习在故障诊断领域中的研究现状与挑战

任浩¹, 屈剑锋^{1†}, 柴毅^{1,2,3}, 唐秋¹, 叶欣³

(1. 重庆大学自动化学院, 重庆 400044; 2. 电力传输设备与系统安全国家重点实验室, 重庆 400044;
3. 航天发射场可靠性技术重点实验室, 海口 570100)

摘要: 现代工业系统已呈现出向大型化、复杂化的方向发展,使得针对工业系统的故障诊断方法遇到一系列的技术难题. 近年来,深度学习(deep learning)在特征提取与模式识别方面显示出独特的优势与潜力,将深度学习应用于解决复杂工业系统故障诊断的研究已初现端倪. 为此,首先介绍几种典型的基于深度学习方法实现工业系统故障诊断方法;然后对基于深度学习实现故障诊断的主要思想和建模方法进行描述;最后总结和讨论了复杂工业系统故障的特点,并探讨了深度学习在实现复杂工业系统故障诊断方面所面临的挑战,展望了未来值得继续研究的方向.

关键词: 深度学习; 复杂工业系统; 特征提取; 故障检测与识别

中图分类号: TP277

文献标志码: A

Deep learning for fault diagnosis: The state of the art and challenge

REN Hao¹, QU Jian-feng^{1†}, CHAI Yi^{1,2,3}, TANG Qiu¹, YE Xin³

(1. School of Automation, Chongqing University, Chongqing 400044, China; 2. State Key Laboratory of Power Transmission Equipment and System Security and New Technology, Chongqing 400044, China; 3. Key Laboratory of Space Launching Site Reliability Technology, Haikou 570100, China)

Abstract: Modern industrial system has been developed into the direction of more and more larger and complex, which makes the fault diagnosis for industrial system present a series of technical problems. In recent years, deep learning has shown its unique potentials and advantages in feature extraction and pattern recognition. And the application of deep learning to achieve fault diagnosis of complex industrial systems has begun on its initial exploration stage. In this paper, several typical methods based on deep learning have been introduced first, which can be employed to realize the fault diagnosis for industrial system. And then, the main idea and model approach for fault diagnosis based on deep learning have been described. Finally, the characteristics of faults in complex industrial system have been summarized and discussed, and the challenge of deep learning in realizing the fault diagnosis for complex industrial system has also been studied and discussed.

Keywords: deep learning; complex industrial system; feature extraction; fault detection and diagnosis

0 引言

随着计算机、传感器及通信技术的不断发展,现代工业系统呈现向大型化、复杂化方向发展的新趋势^[1],反映系统运行机理和状态的数据呈现出海量、多模态、不确定性、涌现性、多源异构性和价值低密度性等“大数据”特性,使得传统数据驱动的故障诊断方法无法适应新时期这种工业“大数据”特性的故障诊断需求. 同时,众多数量的组成单元之间相互关联、相互耦合,整个系统具有强烈的不确定性和非线性特征,无法完全依靠传统方法建立精确的物理模

型进行管理监控,检测、定位、隔离复杂工业系统的故障难度较传统系统高^[1-2].

通常所说的故障被定义为至少一个系统特征或者变量出现了不被允许的偏差,而故障诊断技术是对系统的运行状况进行监测,判断是否有故障发生,同时确定故障发生的时间、位置、大小和种类等情况,即完成故障检测、分离和预测^[3-4]. 然而,由于现代复杂工业系统组件及其内部之间一般都存在很多错综复杂、强关联耦合的相互关系,且不确定性因素及不确定性信息充斥其间,使得具有随机性、继发性、并发

收稿日期: 2016-12-22; 修回日期: 2017-04-03.

基金项目: 国家自然科学基金项目(61275162); 重庆市基础与前沿研究计划项目(cstc2016jcyjA0504).

作者简介: 任浩(1990—),男,博士生,从事智能控制系统、模式识别与匹配、故障诊断的研究;柴毅(1962—),男,教授,博士生导师,从事信息融合、故障诊断、控制理论与应用等研究.

[†]通讯作者. E-mail: qujianfeng@cqu.edu.cn

性、传播性等性质的故障频繁出现^[3,5],传统的针对单一设备、子系统、子单元的故障诊断方法难以发现组成单元之间的关联关系,误诊、漏诊的概率极大。

近年来,深度学习在学术界和工业界发展迅猛,在很多传统的识别任务上显著地提高了识别准确率,彰显了其高超的处理复杂识别任务的能力,吸引了大批专家学者对其理论与应用展开研究^[6]。许多领域的专家学者开始尝试利用深度学习理论解决各自领域的一些难题。

深度学习的概念起源于人工神经网络的研究,有多个隐含层的多层感知器是深度学习模型的显著特征。当前的神经网络大多是针对较低水平的网络,即浅层神经网络,如典型的基于单输入单输出神经网络模型的故障诊断方法。而将非线性运算组合水平较高的网络称为深度结构神经网络,如基于单输入、多隐层、单输出神经网络的故障诊断方法。相较于浅层神经网络而言,深度指的是网络学习得到的函数中非线性运算组合水平的数量,或者说隐含层的层数,又称为网络深度。不同于浅层学习算法,深度学习算法具有更好的逼近复杂函数的能力。该类算法一般包含多隐层结构,以实现数据特征的逐层转换,保证最有效地信息提取与特征表达^[7-8]。

深度学习经过近10年的发展,已具有很多其他网络学习算法不可比拟的优势。在表达复杂目标函数能力方面,可以很好地实现高变函数等复杂高维函数的表示;从仿生学角度看,其网络结构是对人类大脑皮层处理信息方法的最佳模拟,即对输入数据采用分层处理的方式进行;在信息共享方面,其训练所获取的多重水平的提取特征可在类似的不同任务中重复使用,可处理很多无标签的数据^[7-9]。但是,深度学习在网络结构的计算复杂度方面,采用某一深度的网络结构可以实现某一非线性函数的紧凑表达,而再采用小于这一深度的网络结构表达该函数时,常常需要增加指数级规模数量的计算因子,从而大大增加了计算的复杂度,并且需要增加训练样本对计算因子中的参数值进行调整,以增加其泛化能力,而当训练样本数量有限而计算因子数量增加时,其泛化能力会变得很差^[7-10]。

本文在分析和总结了近年来国内外采用深度学习实现工业系统故障诊断的研究现状基础上,从深度学习在故障诊断领域的特征提取与模式识别等原理出发,阐述了现代复杂工业系统故障呈现出的新特点与难点,并探讨了未来深度学习在实现工业系统故障诊断的核心思想和存在的挑战,展望了未来值得

继续研究的方向。

1 深度学习在故障诊断领域的研究现状

深度学习的“学习”主要集中在对数据的有效表示,试图找到数据的内部结构,发现变量之间的本质关系。相关研究表明,数据表示的方式对训练学习成功与否将产生很大的影响,好的表示能够消除输入数据中与学习任务无关因素的改变对学习性能的影响,同时保留对学习任务有用的信息^[7-8]。

近年来,较为公认熟悉的深度学习的基本模型框架包括深度置信网络(DBN)^[11-34]、卷积神经网络(CNN)^[35-45]、堆叠自动编码器(SAE)^[46-65]、递归神经网络(RNN)^[66-97]。为便于清楚地阐述深度学习在故障诊断领域的研究现状,本节将重点阐述基于以上4种深度学习模型实现故障诊断的主要思想和方法。

1.1 深度置信网络(DBN)的故障诊断研究现状

DBN是一种典型的深度学习算法,可以通过组合底层特征形成更加抽象的高层表示,发现数据的分布式特征,其动机在于建立模型模拟人类大脑的神经网络连接结构,通过多个非线性运算隐含层的多层感知器对输入数据进行分布式表征,并且能够在样本集有限的情况下实现学习数据集的本质特征,达到实现量测数据从低级到高级的特征表示与提取^[9,11]。而特征提取是智能故障诊断方法的首要关键步骤,不同的特征提取方法所得到的不同特征将导致具有巨大差异的故障诊断效果^[10],特征表示、提取与选择将直接影响故障诊断的效果。

DBN是模拟人类大脑处理外部信号的功能、由多个限制玻尔兹曼机(RBM)组成的多隐层神经网络,如图1所示。其核心就是用逐层贪婪学习算法来优化

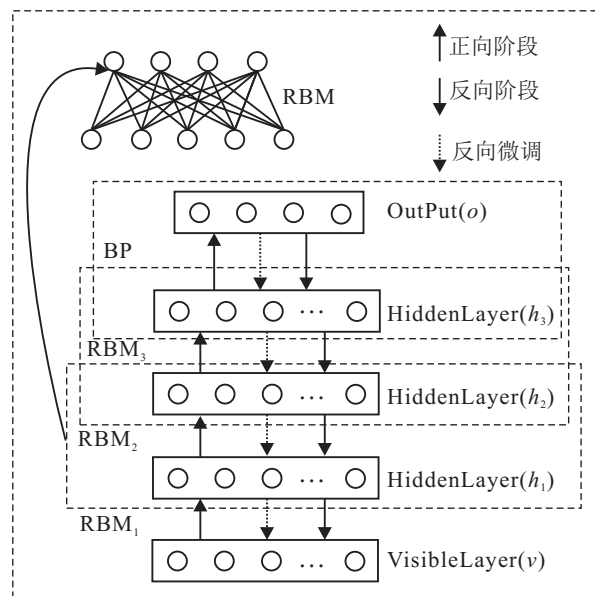


图1 深度置信网络DBN架构及其训练过程

深度神经网络的连接权重,即首先使用无监督逐层训练的方式,有效地挖掘待诊断设备运行状态信号中的故障特征,然后在相应的分类器中,通过反向的有监督微调来优化DBN的故障识别能力^[9,11-34]。其关键的特征提取能力的实现就是其具有的无监督逐层训练方法,可直接将数据从输入映射到输出,构建一些高度复杂的非线性函数。

DBN可直接从低层原始信号出发,通过逐层贪婪学习得到高层特征表示,避免特征提取与选择的人工操作,有效地消除传统人工特征提取与选择所带来的复杂性和不确定性,增强识别过程的智能性^[8-9,12],如图2所示。相较于传统的其他故障诊断方法,其优势首先在于能够摆脱对大量信号处理技术与诊断经验的依赖,完成故障特征的自适应提取与健康状态的智能诊断;其次,该方法对时域信号没有周期性要求,具有较强的通用性和适应性;最后是其具有处理高维、非线性数据的能力,且可有效地避免发生维数灾难和诊断能力不足等问题^[14]。从此角度看,深度置信网络非常适合处理新时期工业“大数据”的故障诊断难题。

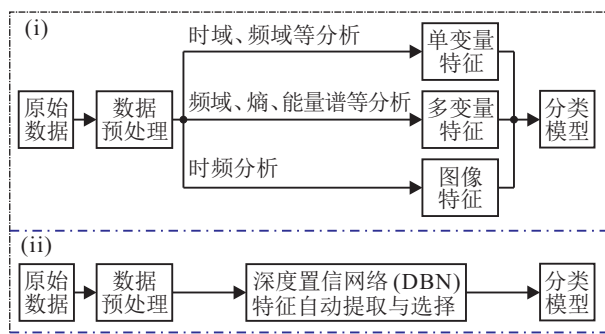


图2 基于DBN故障诊断(ii)与其他故障诊断(i)的异同

目前,采用DBN实现有关故障的诊断与识别还处于初步探索阶段。文献[9]首先对DBN在信号与信息处理方面的应用进行总结,并综述其在语音信号处理与识别、图像处理与模式识别以及语言处理与信息提取等方面的研究,而此时DBN在故障诊断领域的应用研究却鲜有报道。Prasanna等在文献[11]中介绍了一种基于DBN的多传感器健康诊断的方法,包含3个连续阶段:1)定义健康状态和训练与测试数据的预处理;2)训练DBN分类识别模型,对预定义的多传感器健康状态进行诊断;3)利用测试数据集对该模型进行有效性验证。此文是将DBN用于实现传感器健康状态特征的分类,而没有实现基于DBN的特征表达与提取,需要进一步深入研究,但确实为实现基于DBN故障诊断方法迈出了一大步。

Van Tung Tran等^[12]则针对具有瞬态冲击和复杂

背景噪声的振动信号展开研究,该对象难以采用传统诊断方法实现故障诊断,为挖掘隐含在信号中的故障模式,文中的DBN考虑并采用了Bernoulli隐含层与Gaussian可视层单元,赋予了DBN处理实际运行数据的能力,推动了其在故障诊断领域的发展。Shao等^[14]、Wang等^[15]和Chen等^[16]均采用DBN实现了滚动轴承和齿轮箱的故障诊断,并与现有一些主流故障诊断算法进行了比较,验证了所提出方法实现故障诊断的鲁棒性和精确性。随后,Li等^[13,17-26]紧跟前人的研究,继续在基于DBN实现高维数据的异常检测与识别、滚动轴承故障诊断、齿轮箱深度故障特征提取与识别以及高背景噪声信息提取与融合等领域展开研究,均取得了传统方法无法比拟的效果与优势。

近年来,能够搜索到的SCI/EI文章持续增加,仅在短短的4年的时间里,SCI/EI文章数就从2013年的仅1篇增加到2016年的16篇。可见,从文章数量上看,其在故障诊断领域具有潜在优势,且其应用领域从传感器健康诊断^[11]到压缩机^[12]、齿轮箱^[13,16,32]、滚动轴承^[14-15,20-24]等,应用领域越来越宽。总结前人采用DBN实现故障检测与识别方法,DBN主要有两种用法:一种用DBN作分类器^[11-12,15-16,22,28,31],另一种用DBN作特征表达、提取与识别^[13-14,17-21,23-27,29-30,32-34]。

总结现有的基于DBN的故障诊断方法,主要包括以下5大步骤:

- 1) 利用传感器获得系统在不同运行状态下的时域监测信号;
- 2) 对时域监测信号进行分批次(每批次的采样点数尽可能保持一致),对分段后的信号进行[0,1]归一化,将数据划分为训练集和测试集;
- 3) 建立一个多隐含层的DBN模型,根据故障样本维数确定DBN模型的输入节点数,使用训练集对DBN模型进行无监督训练;
- 4) 根据故障类别确定DBN模型的输出层节点数,使用BP算法对DBN模型的权重和阈值进行反向微调;
- 5) 利用训练好的DBN模型对测试集或待诊断数据进行故障诊断。

1.2 卷积神经网络(CNN)的故障诊断研究现状

CNN是一个典型的前馈神经网络,其实质是构建多个能够提取输入数据特征的滤波器,通过这些滤波器对输入数据进行逐层卷积及池化,逐级提取隐藏在数据之中的拓扑结构特征,随着网络结构层层深入,提取的特征也逐渐变得抽象,最终获得输入数据的平移、旋转及缩放不变的特征表示。其主要特征

是结合稀疏连接、权重共享、空间或时间上的降采样. 稀疏连接通过拓扑结构建立层与层之间非全连接空间关系来降低训练参数的数目; 权值共享能够有效地避免算法过拟合; 子采样充分利用数据本身

包含的局部性等特征, 减少数据维度, 优化网络结构, 且能保证在一定程度上位移不变性^[35-39], 如图3所示. 因此, CNN 非常适合海量数据的处理与学习.

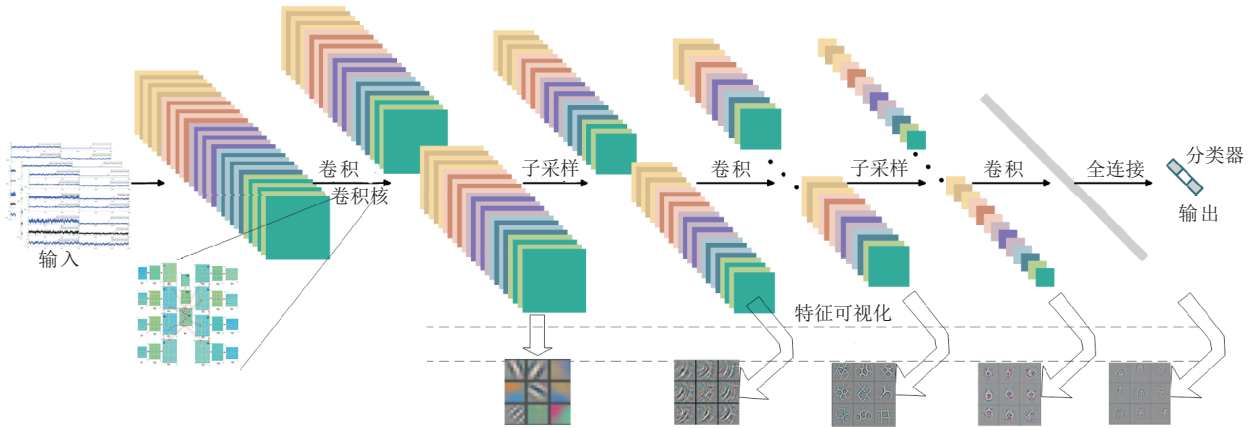


图3 卷积神经网络CNN典型架构

图3给出了经典的卷积神经网络架构, 以及用其实现故障诊断的思想方法. 卷积神经网络的前期分析算法是由卷积和子采样交替进行, 最后接近输出层的算法则采用普通的多层神经网络^[35]. 网络输入为2D的特征图或者原始数据图, 区别于其他网络的是CNN无需将这些输入数据进行矢量化. 在卷积层中, 采用卷积核对前一层特征图进行卷积运算, 同时利用激励函数构建输出特征图. 每一层的输出都是对多输入特征进行卷积, 如此循环往复. 其数学模型可简述为

$$x_j^l = f\left(\sum_{i \in M_j} x_i^{l-1} \times k_{ij}^l + b_j^l\right). \quad (1)$$

其中: M_j 为输入特征图, l 为第 l 层网络, k 表示卷积核, b 为网络偏置, x_j^l 为 l 层输出, x_i^{l-1} 为 l 层输入.

子采样层是对上一层数据图的缩放映射以减少数据维度, 提取的特征具有缩放不变性, 同时还可以防止过拟合, 其神经元的计算方法可表示为

$$x_j^l = f(\beta_j^l \text{down}(x_i^{l-1}) + b_j^l). \quad (2)$$

其中: $\text{down}(\cdot)$ 为子采样函数, β 为网络乘性偏置.

CNN的输出层一般采用上一层级联特征图进行线性全连接, 一般采用softmax分类器, 其优势是可以解决多分类问题, 模型可表示为

$$O = f(b_o + w_o f_v). \quad (3)$$

其中: f_v 为特征向量, b_o 、 w_o 为偏差向量和权值矩阵.

目前, CNN是一种有监督的深度模型架构, 网络的训练类似于传统的人工神经网络训练方法, 采用BP算法将误差逐层反向传递, 使用梯度下降法调整

各层之间的参数. CNN可提取输入数据的局部特征, 并逐层组合抽象生成高层特征, 可有效实现故障诊断与识别^[35].

文献[39]首次提出了采用两个softmax分类器的CNN网络结构, 将输出序列分为两类, 实现对两种非独立分类问题的分类, 用一个网络解决区内外故障判断及故障选相两个非独立分类问题, 更大程度地实现了权值共享. 文献[36]则采用卷积神经网络实现齿轮箱的故障检测与分类问题. 而文献[37]则采用CNN实现了无需专家经验的故障检测与识别算法, 成功解决了旋转机械中外圈滚道故障和润滑性能退化两种传统方法很难实现的故障诊断.

基于CNN算法实现故障诊断还处于初步探索阶段, 公开发表的研究成果比较少. 就现有文献看, 与基于DBN故障诊断方法相似, 主要分为两种: 一种是将CNN作为特征提取与识别的方法^[37,40-41,43-44], 图4(ii)所示; 另一种是将CNN作为分类器使用^[36,38-39,42,45], 图4(i)所示. 另外, 基于CNN的故障诊断算法的研究

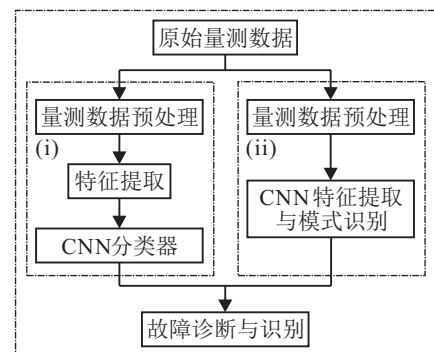


图4 卷积神经网络CNN实现故障诊断与识别的两种不同方法

报道并没有基于DBN的故障诊断算法多,且现有的研究,CNN仅仅用于实现视觉理解、图像特征提取等,很少用于实现基于信号的特征提取与识别.一种可能的解释是CNN输入需要2D特征图谱,即输入数据必须满足2D结构特征^[42].

基于CNN的故障诊断方法仅仅经过两年的发展,研究结果表明,该方法的有效性需要更深入研究,其适合处理何种故障也有待进一步探讨,且随着科技的发展,故障诊断问题面临着海量数据处理难题,而CNN非常适合处理海量数据,学习海量数据中的特征^[38,41-45],识别出海量数据中蕴含的信息.因此,基于CNN的故障诊断是未来基于深度学习故障诊断算法发展的一个方向.

1.3 堆叠自动编码器(SAE)的故障诊断研究现状

堆叠自动编码器(SAE)能有效地提取数据低维特征,其基本单元是自动编码器(AE),由多个AE堆叠而成.每个AE可以视为一个单隐层的人工神经网络,通过寻求最优参数(W, b)使得输出 y 尽可能地重构输入 x ,此时隐层输出 $y_h^{(k,2)}$ 可看作是输入 x 降维后的低维特征,如图5所示.




图5 堆叠自动编码器SAE(i)与自动编码器AE(ii)架构

为使隐含层输出特征更加稀疏鲁棒,AE的损失函数中含有输入输出均方误差约束,权值衰减约束和稀疏性约束3部分,即

$$\begin{aligned} \min_{\arg W, b} L(W, b) = & \left[\frac{1}{m} \sum_{i=1}^m \frac{1}{2} \|y^{(i)} - x^{(i)}\|^2 \right] + \\ & \frac{\lambda}{2} \sum_{l=1}^{n_l-1} \sum_{i=1}^{s_l} \sum_{j=1}^{s_{l+1}} (W_{ji}^{(k,l)})^2 + \\ & \beta \sum_{j=1}^{s_2} KL(\rho \| \bar{\rho}_j). \end{aligned} \quad (4)$$

其中: m 、 n 、 s_l 分别表示样本数、网络层数和 l 层单元数, $W^{k,l}$ 表示层间连接权重, $b_i^{(k,l)}$ 为 l 层的单元偏

置, $\bar{\rho}_j$ 为隐含层单元平均输出,且

$$\begin{cases} y^{(i)} = f(W^{(k,2)}a^{(k,2)} + b^{(k,2)}), \\ a^{(k,2)} = f(W^{(k,1)}x^{(i)} + b^{(k,1)}), \\ f(z) = 1/(1 + e^{-z}). \end{cases} \quad (5)$$

自动编码器(AE)依然采用梯度下降算法训练网络参数,使损失函数(4)最小化.在预训练阶段,从底层开始,每个AE单独训练,以最小化其输出与输入之间的误差为目标,低层AE训练完成后,其隐层输出作为高层AE的输入,继续训练高层AE,以此类推,逐层训练,直至将所有AE训练完成.在全局微调阶段,以训练好的AE输入层与隐层之间的权重和偏置作为堆叠自动编码器的初始权重和偏置,以数据的标签作为监督信号计算网络误差,利用BP算法计算各层误差,使用梯度下降法完成各层权重和偏置的调节.堆叠自动编码器(SAE)是将若干AE级联构建多层神经网络,其输出可看作是输入数据经过多次降维后的特征表示^[47].

近年来,采用SAE方法实现故障诊断愈来愈受到同行专家学者的关注.文献[46]基于深度学习模型提出了一种将SAE和分簇协议相结合的数据融合算法,该算法在各个簇内构建特征提取分类模型,之后将同类特征融合并发送给汇聚节点,提高了无线传感器网络的数据融合性能;Demethual等^[48]针对传统的多目标方法无法解决的具有独特非线性问题的原料处理系统,基于量测信号进行故障诊断,提出了采用扩散图(DM)、局部线性嵌入(LLE)和自动编码器(AE)等相结合的特征提取算法,采用gustafson-kessel和 k -medoids算法对编码信号进行分类.结果表明,此方法实现的故障诊断准确率比传统方法提高了90%;文献[56]则展示了利用基于深度神经网络方法的稀疏自编码算法实现异步电机故障分类问题,其采用具有无监督特征提取优势的稀疏自编码模型来学习故障特征,在降噪编码的作用下有效地提出了特征提取的干扰项,提高了特征表示的鲁棒性,SAE提取特征后将其用于训练神经网络来识别异步电机故障,实验表明,该方法展现了基于深度学习的故障诊断在异步电机故障诊断中所具有的独特优势.类似的研究还扩展至航空发动机^[57]、核电站^[58]、风力发电机组设备^[59]、滚动轴承^[49-50,60]、变压器^[61]、机器人^[52,54]以及旋转机械^[51,63-64]等复杂系统的故障诊断领域,并均取得了良好的效果.

就目前采用SAE实现故障诊断的方法看,SAE主要起到的作用是降噪滤波和特征提取两大功

能^[53-55,62],其不同于基于DBN、CNN的故障诊断方法,用SAE实现故障诊断从其开始就用于实现特征提取与故障分类.一个可能的解释是无论是编码器还是解码器均可用于整合特征提取算法与分类识别算法^[65].换句话说,SAE的训练需要少量的样本数据,再加上适当的分类识别技术即可实现较高性能的故障诊断效果,充分展现了其强大的特征提取能力以及该方法的鲁棒性.

1.4 递归神经网络(RNN)的故障诊断研究现状

RNN的本质特征是其处理单元之间既有内部的反馈连接又有前馈连接,其内部反馈连接可以为网络保留隐层节点的状态和提供记忆方式,网络的输出不仅取决于当前的输入,而且与以前的网络内部状态有关,体现出了较好的动态特性^[66-67],如图6所示.

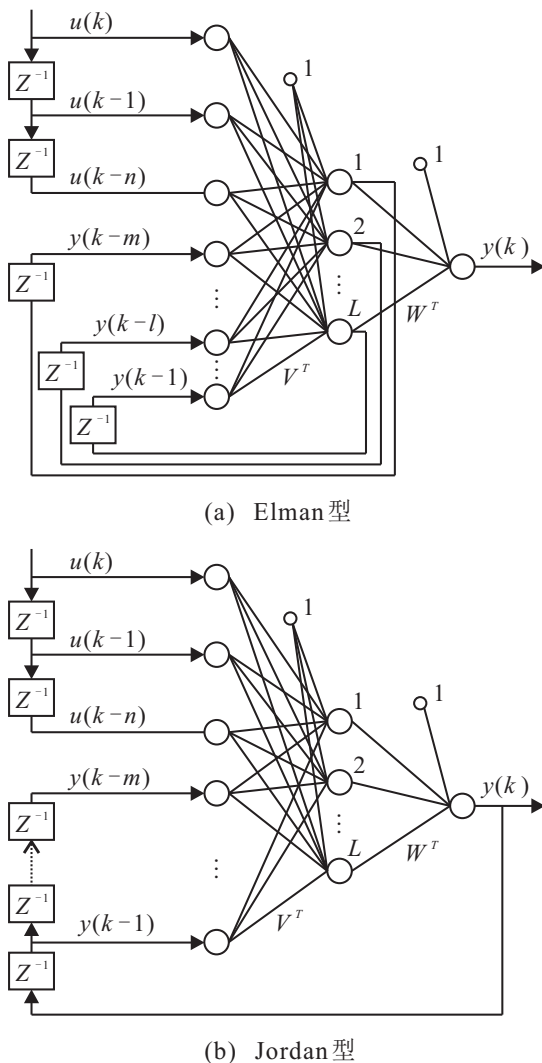


图6 Elman型和Jordan型双层递归神经网络RNN架构

RNN根据反馈途径不同可构成Jordan和Elman型两种不同的递归神经网络^[67],如图6所示. Elman网络可以看作是一个具有局部记忆单元和局部反馈连接的前向神经网络,具有与多层前向网络相似

的多层结构.在该Elman网络中,除了普通的隐层外,还有一个特别的关联层,该层从隐层接收反馈信号,每一个隐层节点都有一个与之对应的关联层节点连接.关联层的作用是通过联接记忆将上一时刻的隐层状态连同当前时刻的网络输入一起作为隐层的输入,相当于状态反馈^[77]. Elman网络的数学模型为

$$\begin{cases} x(k) = f(W^1 x_c(k) + W^2 u(k-1)), \\ x_c(k) = \alpha x_c(k-1) + x(k-1), \\ y(k) = g(W^3 x(k)). \end{cases} \quad (6)$$

其中: $u(k-1)$ 、 $y(k)$ 、 $x(k)$ 、 $x_c(k) \in R$ 为网络的外部输入、网络输出、隐含层输出以及承接层输出, W^1 、 W^2 、 $W^3 \in R$ 分别为承接层到隐含层、输入层到隐含层以及隐含层到输出层的连接权矩阵, $f(\cdot)$ 、 $g(\cdot)$ 分别为隐含层单元和输出层单元的激发函数所组成的非线性向量函数, $0 \leq \alpha \leq 1$ 为自连接反馈增益因子.

Jordan网络与Elman网络相比,它表示动态系统的能力较弱,因其网络中不存在状态反馈,其包含的是输出反馈,因此只有反映到输出的特性可由Jordan网络表达^[78].其数学函数与Elman网络唯一不同的就是承接层的输出

$$x_c(k) = y(k-1) + \alpha x_c(k-1). \quad (7)$$

RNN与DBN、SAE、CNN最大的不同之处在于其充分考虑了样本之间的关联关系,这种关联关系是以神经网络之间的连接体现出来的,单个神经网络的隐含层连接至其前后神经网络的隐层,这种连接方式考虑了前后样本对当前样本的影响.一般认为,RNN的各个神经网络具有相同的权重和偏置,RNN训练时,可使用RBM或者AE对其进行预训练来初始化网络参数,然后计算每个样本的输出误差,并以累积误差训练网络参数. RNN可用于处理时序数据或者前后关联数据^[95],RNN还可以与CNN结合使用,考虑处理样本之间相关性的问题^[90].且RNN可在样本学习训练时将原有学习样本和新的学习模式一起重新进行训练,使网络学习记忆具有良好的稳定性^[75,92-96].

在故障诊断方面,RNN提高了故障诊断效率,改善了现有神经网络故障诊断方法,适用于复杂设备或系统的实时故障诊断^[70-72],且具有良好的扩展性.基于RNN故障诊断方法历经了近10年的发展,其成果可谓遍布各个领域.文献[68]将递归神经模糊系统应用于核反应堆的故障检测与隔离,其中RNN被用于实现系统状态的演化与识别,并设计了BP神经网络与该网络进行对比,验证了RNN在故障检测

与隔离方面具有良好的泛化能力。Azzam等^[69]则将RNN应用于无线传感器网络的故障检测与识别,采用RNN实现对传感器节点、节点动力学以及内部连接耦合性进行建模,而后采用神经网络实现了传感器节点的故障检测与识别,并将其与Kalman滤波器方法进行比较,验证了所提架构的有效性。Talebi等^[73]则针对在非线性系统的状态和传感器均不确定或含有干扰的情况下,采用两种RNN实现了系统未知传感器或执行器故障的检测与隔离,并将其应用在低轨道地球卫星上,大量仿真实验验证了该方法的有效性与稳定性。文献[74]提出了一种基于Elman神经网络的旋转机械故障诊断模型,其综合了经验模态分解的特征提取和Elman神经网络在故障模式识别方面的优势,通过对深沟球轴承故障诊断实例验证了所提故障诊断模型的有效性;而同年Wu等^[76]则针对机器人系统的离散时间多输入多输出的故障容错控制进行了研究,提出了一种新颖的多输入多输出的递归神经网络,并给出了其训练方法,该方法已很好地应用在了二阶机器人手臂位置跟踪控制系统的容错控制中。

近3年来,由于深度学习具有强大的特征提取能力,基于RNN的故障诊断算法又再次得到了同行学者的广泛关注。Pratik等^[82]针对在所有情况下实现基于假设或单一分布式模型无法实现的参数软件可靠性模型的精确预测,设计了动态权值学习更新的鲁棒RNN模型,更加合理地实现参数软件可靠性预测,并将其与其他方法进行了比较,说明了该方法在拟合和预测误差方面所具有的独特优势;而Nasser等^[83]则使用RNN来实现对风力发电系统的运行行为建模,通过比较真实系统输出和模型输出得出残差,实现故障的识别,仿真表明该方法可在很短的时间内实现故障检测,并且具有非常低的误报和漏警率;文献[85]采用递归神经网络构建预测控制器,以实现提前一步预测系统状态;Piotr等^[86]则利用局部RNN来实现对混沌工程系统的混沌行为进行学习,进而实现系统鲁棒性的故障检测。Lin等^[88]构建了一个递归模糊神经网络模型来实现六阶永磁同步电机位置伺服驱动器的容错控制;Mrcin等^[94]针对动态非线性系统的执行器故障诊断的鲁棒性问题,提出采用RNN进行故障诊断建模,将问题转化为相关参数的线性求取问题,该方法在保证观测器收敛性的前提下,采用执行器故障估计误差来描述扰动衰减水平,并将其很好地应用在了未知输入观测器的情况,解决了执行器故障估计的鲁棒性问题。

递归神经网络具有收敛速度快、精度高、稳定性好、扩展性好等优势,此外RNN在预测方面具有其他算法不可比拟的优势^[77,86-89,91-97],使其在近年来深度学习故障诊断中屡屡备受重视。在系统呈现向大型化、复杂化发展的背景下,RNN故障诊断方法将会发挥越来越重要的作用。

2 深度学习在故障诊断领域的难点与挑战

故障诊断技术是提高系统可靠性和安全性的重要手段,形成了涉及信号获取与传感技术、故障机理与征兆联系、信号处理与诊断方法、智能决策与诊断系统等方面较为完善的理论体系。近年来,由于系统设备日趋复杂、智能化及机电一体化,传统的诊断技术已很难满足现代系统设备的故障诊断需求,迫切需要信号分析、建模与知识处理相融合的智能故障诊断技术^[4,10]。

由于被诊断对象日趋复杂,获取准确、完备、有效的诊断知识越来越困难,而深度学习(deep learning)是通过建立深层神经网络模拟人脑的信息处理机制来学习、解释并分析学习输入数据,获得解读数据知识的能力,同时根据输入数据特征自动调整与更新网络权重,提高特征提取或者学习新知识的能力^[6,9]。然而,特征提取的完整与否,知识挖掘的是否彻底也是实现故障诊断的关键。

2.1 复杂工业系统的故障特性

针对复杂工业系统的故障诊断,由于其功能单元很多,各个单元及其组合部件都可能产生不同的故障,使得传统诊断技术难以实现实时、准确的故障识别,同时,复杂工业系统内部相互制约,使得工业系统故障又呈现出新的特性^[5-6]。

1) 层次性。复杂工业系统在构造上由多个子系统组成,结构可以划分为系统、子系统、部件、元件等各个层次,从而形成其功能的层次性,故障和征兆具有不同的层次性。

2) 传播性。

i) 纵向传播,元件的故障相继引起部件、子系统、系统的故障;

ii) 横向传播,故障在同一层次内传播;

iii) 短时间内多个不同源故障同时(或相继)发生,某一简单故障在同一时间点上导致多个子系统功能异常,以及多种类型故障的并发与相互转化等。

3) 相关性。某一故障可能对应若干征兆,某一征兆可能对应多个故障。

4) 不确定性。数据采集、传输、存储过程中的异常以及传感器自身漂移等,使得系统的故障和征兆具

有随机性、模糊性和某些信息的不确定性等特点。

5) 大数据特性. 随着信息化的发展, 复杂工业系统不仅在时间尺度上不断存储积累这些运行数据, 还在空间尺度上扩展采集设备、人之间及内部传输的数据, 从而获得时间与空间两个维度上不同尺度的海量数据, 以及分散在各生产部门的多源不同类型的文本、图像、声音等数据^[8,98]。

6) 复杂性. 现代工业系统的设备复杂化和规模大型化, 使得系统在运行过程中不可避免地产生损伤, 出现早期故障^[4], 这些损伤和早期故障往往具有潜在性和动态响应微弱性, 复合故障^[2]和系统故障由于多因素耦合和传递路径复杂, 以及持续时间短、可反复出现, 未经处理可自行消失的间歇故障^[99]也常常出现在复杂工业系统中。

2.2 深度学习故障诊断的挑战性问题

采用深度学习方法实现系统故障诊断的研究已初现端倪, 就已有的研究报道, 其基本思想为: 被检测工业系统对象全部可能发生的运行状态(正常或故障)组成状态空间, 可观测特征取值范围的全体构成了特征空间, 当系统处于某一状态时, 系统具有某种确定的状态特征, 反之, 一定的特征也对应某种确定的状态^[6-7]。深度学习的目的就是试图通过寻求可量测的特征向量来判断系统处于何种状态, 进而实现工业系统的故障检测、诊断与识别匹配等^[10, 100-103]。

深度学习的故障诊断策略是模拟人类思维的学习以及推理过程, 通过有效的特征提取、选择和分类识别处理诊断信息, 模拟人类专家, 以灵活的诊断策略对监测对象的运行状态和故障作出智能判断和决策^[6,9]。经过近几年的发展, 深度学习的故障诊断策略已初见相关报道, 但还有一些挑战性的问题有待进一步研究。

1) 特征提取与故障机理映射. 故障机理是指通过理论或大量的实验分析, 得到反映设备故障状态信号与设备系统参数之间的关联映射规律。由于通常获得某一系统较全面的故障数据样本是不现实的, 如何将深度学习与现有欠故障机理相结合, 解决复杂工业系统故障的“相关性”问题, 实现系统运行状态特征的有效提取是一个极具挑战性的问题, 目前还没有明显突破性的进展^[4, 99, 104-107]。

作者认为一个可能的研究思路是构建实验仿真分析平台, 注入不同类型的故障, 得到不同故障对应的仿真信号, 利用RNN实现每个故障特征信号的预测, 进而与现有量测到的系统状态信号作残差, 通过设定阈值实现故障检测, 以此实现特征提取与故障机

理的映射^[47, 77-84, 91-94]或许是一个可行的研究思路。

2) 复杂性故障诊断. 故障诊断方法研究中提出了许多有效的“望闻问测”诊断手段, 但针对早期故障、微弱故障、复合故障、系统故障等的诊断方法还存在不足, 可靠的诊断方法有限, 系统运行过程中不可避免地产生损伤和出现早期故障, 其具有潜在性和动态响应微弱性。复合故障和系统故障由于多因素耦合和传递路径复杂, 往往导致单一信号处理方法难以有效溯源故障成因, 而目前针对此复杂性故障有效的解决方案就是增加传感器, 力求通过增加监测手段实现该类复杂性故障的检测与诊断^[4, 99, 104-107]。

由于复杂性故障往往伴随着海量的监测数据, 作者认为一种可能的基于深度学习的故障诊断方法是将量测数据组合为2维数据图谱或者特征图谱。而CNN非常适合处理海量数据, 学习海量数据中的特征, 实现多层次、非线性的复杂特征提取, 捕捉到不明显、特征信息微弱的征兆, 以建立多维和多参数复杂系统模型, 而后从系统的整体性和系统的关联性出发, 研究系统内部各组分之间的动力学特性、相互作用和依赖关系, 探索出系统故障的根源^[18, 38, 40-41, 43, 108-117]。

3) 故障诊断模型的参数优化调整. 深度学习模型的训练速度远比线性模型慢, 且受制于训练数据集。虽然深度学习算法有利于解决复杂工业系统故障的“大数据”特性, 但对于优化学习模型参数的研究可见报道很少, 这无疑是一大阻碍。因此, 在模型构建过程中模型参数的动态优化调整也将是其发展的一大挑战^[118-119]。

无监督学习是网络训练的核心方法之一, 其对具有不同深度的网络训练误差的影响是不同的。目前深度学习网络的深度确定方法并没有统一方法, 本文认为, 对于模型参数优化, 可能的方法是利用小样本故障数据, 构建重构误差、分类误差、输入输出误差等实现模型参数训练的优化性约束性调整^[18, 118-119]。

4) 分布式深度学习故障诊断模型. 随着工业生产的连续化、高速化、系统化、自动化和企业管理的网络化, 工业大型成套关键设备已呈现为分布式开放的规模化系统, 具有鲜明的层次性^[104]。分布式故障诊断技术的发展将为大规模诊断系统设计与实现提供一条极具潜力的途径。该技术可为解决大规模故障的智能诊断, 构成分散的面向特定问题或故障设备相对简单的子系统, 协调各子系统并行地、相互协作地进行故障诊断与系统可靠性评估将是未来亟需进一步研究的方法。如何建立基于深度学习的分

布式故障诊断算法自然而然地成为了一大挑战性问题^[4, 99, 104-107]。

深度学习的首要特点是堆叠各式各样的低层次学习模型。作者认为,实现分布式深度学习故障诊断模型就是将RBM、AE等分布于各个子系统子设备中,实现初级故障特征提取等,将深度学习神经网络融合于现有复杂工业系统中,通过系统结构来确定分布式深度学习网络的拓扑结构,采用量测数据驱动整个深度学习网络,通过实际目标监测参数值与网络输出值进行对比,进行实现整个系统的故障诊断^[18, 81, 91, 96]。

5) 适用于工业大数据的深度学习故障诊断模型。随着信息化技术的发展,现代复杂工业系统涌现了海量的数据,如何设计出一个适用于多源输入数据,同时具有较好功能的特征提取模型来解决复杂工业系统“大数据”难题,实现复杂工业系统故障诊断也是其中的一个挑战^[98]。

海量的正常运行数据与小样本的故障状态数据是工业大数据的一个典型特点,而深度学习又需要大量的样本进行训练,二者之间的矛盾似乎不可调和^[38]。本文认为,可以采用另一种思路,即采用正常运行状态下的数据训练深度学习模型,当故障发生时,该网络输出值与正常值具有较大偏差,如此,异常运行状态的检测便可以实现了。而对于故障诊断,则需要结合其他方法进行,或者开发出其他类型深度学习网络以适应工业大数据的故障诊断^[8, 91, 108-117]。

6) 混合深度学习与传统故障诊断模型。纵观现有的故障诊断模型,目前还远没有达到“相互兼容”的程度,各种方法均有各自的优势,往往给人留下“黑匣子”和“因人而异”的印象,其泛化能力备受质疑^[105]。如何针对不同模型的特点,取长补短、优势互补,实现不同模型相互融合与协同,对复杂工业系统的故障诊断工作而言是非常关键的^[31-34, 99, 104-107]。

SAE是由多个AE堆叠而成,而每个AE可以看作一个单隐层的神经网络。笔者认为,AE可不可以是与神经网络功能类似的其他方法,进行组合成为具有优异性能的混合深度学习模型,以实现不同模型间相互融合与协调^[17-18, 47, 65, 91, 114, 120]。

7) 深度学习故障诊断特征提取与识别。目前,深度学习的特征提取模型需要调节模型层数和模型参数,需要不断地尝试与试验,需要极大的经验进行模型训练,而当应用于新的运行数据,或者说外部环境变化导致数据偏离原有的结构时,模型无法自适应调整。因此,在模型层数定量确定后,小样本模型训练等

也是一个极具挑战的问题^[4, 99, 104-107]。

目前,深度学习网络的模型层数和模型参数确定并没有统一方法。笔者认为,从重构误差、分类误差、损失函数最小化等角度,以及从最大化提取特征数量、识别精确度等最大化来实现有监督的模型训练,将网络训练成为一个非线性优化问题不失为一种可行的解决思路^[18, 91, 108-119]。

8) 训练样本多源不统一且海量。现代复杂工业系统产生了海量的时间与空间尺度上的运行数据,以及分散不统一的数据类型,如何将深度学习与现有训练数据相结合,构建易于训练,可自适应协调多源海量数据也是一个值得研究的方向^[98]。

笔者认为,构建不同类型的、各自独立的子网络来处理不同类型的数据,通过平移、旋转、缩放不变以及转码等方式,将数据转化为统一的数据类型,而后再构建一个深度学习网络从这些数据中提取有用的特征,以实现训练数据样本的统一,以及解决海量数据的处理问题不失为一种可行的思路^[8, 18, 47, 108-117]。

3 结 论

本文在分析和总结了近几年国内外采用深度学习实现工业系统故障诊断的研究现状基础上,阐述了新时期工业系统故障的特点,以及未来在复杂工业系统应用深度学习实现故障诊断将要面临的挑战进行了阐述,并提出了作者对此挑战的解决思路。

参考文献(References)

- [1] 李晗, 萧德云. 基于数据驱动的故障诊断方法综述[J]. 控制与决策, 2011, 26(1): 1-16.
(Li H, Xiao D Y. Survey on data driven fault diagnosis methods[J]. Control and Decision, 2011, 26(1): 1-16.)
- [2] 张可, 周东华, 柴毅. 复合故障诊断技术综述[J]. 控制理论与应用, 2015, 32(9): 1143-1157.
(Zhang K, Zhou D H, Chai Y. Review of multiple fault diagnosis methods[J]. Control Theory & Applications, 2015, 32(9): 1143-1157.)
- [3] 周东华, 刘洋, 何潇. 闭环系统故障诊断技术综述[J]. 自动化学报, 2013, 39(11): 1933-1943.
(Zhou D H, Liu Y, He X. Review on fault diagnosis techniques for closed-loop systems[J]. Acta Automatica Sinica, 2013, 39(11): 1933-1943.)
- [4] 文成林, 吕菲亚, 包哲静, 等. 基于数据驱动的小故障诊断方法综述[J]. 自动化学报, 2016, 42(9): 1287-1299.
(Wen C L, Lv F Y, Bao Z J, et al. A review of data driven-based incipient fault diagnosis[J]. Acta Automatica Sinica, 2016, 42(9): 1287-1299.)
- [5] 桂卫华, 刘晓颖. 基于人工智能方法的复杂过程故障诊断技术[J]. 控制工程, 2002, 9(4): 1-6.

- (Gui W H, Liu X Y. Fault diagnosis technologies based on artificial intelligence for complex process[J]. Control Engineering of China, 2002, 9(4): 1-6.)
- [6] 段艳杰, 吕宜生, 张杰, 等. 深度学习在控制领域的研究现状与展望[J]. 自动化学报, 2016, 42(5): 643-654.
(Duan Y J, Lv Y S, Zhang J, et al. Deep learning for control: The state of the art and prospects[J]. Acta Automatica Sinica, 2016, 42(5): 643-654.)
- [7] Feng Jia, Yaguo Lei, Jing Lin, et al. Deep neural networks: A promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with massive data[J]. Mechanical Systems and Signal Processing, 2016(S72-73): 303-315.
- [8] Qingchen Zhang, Laurence T Yang, Zhikui Chen. Deep computation model for unsupervised feature learning on big data[J]. IEEE Trans on Services Computing, 2016, 9(1): 161-171.
- [9] Dong Yu, Li Deng. Deep learning and its applications to signal and information processing[J]. IEEE Signal Processing Magazine, 2011, 28(1): 145-154.
- [10] 李伟. 复杂系统的智能故障诊断技术现状及其发展趋势[J]. 计算机仿真, 2004, 21(10): 4-7.
(Li W. Advance of intelligent fault diagnosis for complex system and its present situation[J]. Computer Simulation, 2004, 21(10): 4-7.)
- [11] Prasanna Tamilselvan, Pingfeng Wang. Failure diagnosis using deep belief learning based health state classification[J]. Reliability Engineering and System Safety, 2013, 115(7): 124-135.
- [12] Van Tung Tran, Faisal AlThobiani, Andrew Ball. An approach to fault diagnosis of reciprocating compressor valves using Teager-Kaiser energy operator and deep belief networks[J]. Expert Systems with Applications, 2014, 41(9): 4113-4122.
- [13] Chuan Li, René-Vinicio Sánchez, Grover Zurita, et al. Multimodal deep support vector classification with homologous features and its application to gearbox fault diagnosis[J]. Neurocomputing, 2015, 168(C): 119-127.
- [14] Haidong Shao, Hongkai Jiang, Xun Zhang, et al. Rolling bearing fault diagnosis using an optimization deep belief network[J]. Measurement Science and Technology, 2015, 26(11): 115002.
- [15] Wang Xingqing, Li Yanfeng, Ting Rui, et al. Bearing fault diagnosis method based on Hilbert envelope spectrum and deep belief network[J]. J of Vibroengineering, 2015, 17(3): 1295-1308.
- [16] Zhiqiang Chen, Chuan Li, René-Vinicio Sánchez. Multi-layer neural network with deep belief network for gearbox fault diagnosis[J]. J of Vibroengineering, 2015, 17(5): 2379-2392.
- [17] Jingwei Qiu, Wei Liang, Laibin Zhang, et al. The early-warning model of equipment chain in gas pipeline based on DNN-HMM[J]. J of Natural Gas Science and Engineering, 2015, 27: 1710-1722.
- [18] Sarah M Erfani, Sutharshan Rajasegarar, Shanika Karunasekera, et al. High-dimensional and large-scale anomaly detection using a linear one-class SVM with deep learning[J]. Pattern Recognition, 2016, 58: 121-134.
- [19] 赵光权, 葛强强, 刘小勇, 等. 基于DBN的故障特征提取与诊断方法研究[J]. 仪器仪表学报, 2016, 37(9): 1946-1953.
(Zhao G Q, Ge Q Q, Liu X Y, et al. Fault feature extraction and diagnosis method based on deep belief network[J]. Chinese J of Scientific Instrument, 2016, 37(9): 1946-1953.)
- [20] Meng Gan, Cong Wang, Chang'an Zhu. Construction of hierarchical diagnosis network based on deep learning and its application in the fault pattern recognition of rolling element bearings[J]. Mechanical Systems and Signal Processing, 2016(S72-73): 92-104.
- [21] 单外平, 曾雪琼. 基于深度信念网络的信号重构与轴承故障识别[J]. 电子设计工程, 2016, 24(4): 67-71.
(Shan W P, Zeng X Q. Signal reconstruction and bearing fault identification based on deep belief network[J]. Electronic Design Engineering, 2016, 24(4): 67-71.)
- [22] Jie Tao, Yilun Liu, Dalian Yang. Bearing fault diagnosis based on deep belief network and multi-sensor information fusion[J]. Shock and Vibration, 2016, 9306205.
- [23] 李巍华, 单外平, 曾雪琼. 基于深度信念网络的轴承故障分类识别[J]. 振动工程学报, 2016, 29(2): 340-347.
(Li W H, Shan W P, Zeng X Q. Bearing fault identification based on deep belief network[J]. J of Vibration Engineering, 2016, 29(2): 340-347.)
- [24] Chuan Li, Rene-vinicio Sanchez, Grover Zurita, et al. Fault diagnosis for rotating machinery using vibration measurement deep statistical feature learning[J]. Sensors, 2016, 16(6): 895.
- [25] Hai B Huang, Xiao R Huang, Ren X Li, et al. Sound quality prediction of vehicle interior noise using deep belief networks[J]. Applied Acoustics, 2016, 113: 149-161.
- [26] 张新伯, 唐炬, 潘成, 等. 用于局部放电模式识别的深度置信网络方法[J]. 电网技术, 2016, 40(10): 3272-3278.
(Zhang X B, Tang J, Pan C, et al. Research of partial discharge recognition based on deep belief nets[J]. Power System Technology, 2016, 40(10): 3272-3278.)
- [27] Yun Bai, Zhiqiang Chen, Jingjing Xie, et al. Daily reservoir inflow forecasting using multiscale deep feature learning with hybrid models[J]. J of Hydrology, 2016, 532: 193-206.
- [28] Shengnan Wu, Laibin Zhang, Wenpei Zheng, et al. A DBN-based risk assessment model for prediction and

- diagnosis of offshore drilling incidents[J]. J of Natural Gas Science and Engineering, 2016, 34: 139-158.
- [29] Linxia Liao, Wenjing Jin, Radu Pavel. Enhanced restricted boltzmann machine with prognosability regularization for prognostics and health assessment[J]. IEEE Trans on Industrial Electronics, 2016, 63(11): 7076-7083.
- [30] Jiateng Yin, Wentian Zhao. Fault diagnosis network design for vehicle on-board equipment of high-speed railway: A deep learning approach[J]. Engineering Applications of Artificial Intelligence, 2016, 56: 250-259.
- [31] Delong Feng, Mingqing Xiao, Yingxi Liu, et al. Finite-sensor fault diagnosis simulation study of gas turbine engine using information entropy and deep belief networks[J]. Frontiers of Information Technology & Electronic Engineering, 2016, 17(2): 1287-1304.
- [32] Chuan Li, Rene-Vinicio Sanchez, Grover Zurita, et al. Gearbox fault diagnosis based on deep random forest fusion of acoustic and vibratory signals[J]. Mechanical Systems and Signal Processing, 2016(S76-77): 283-293.
- [33] Xueheng Qiu, Ye Ren, Ponnuthurai Nagaratnam Suganthan, et al. Empirical mode decomposition based ensemble deep learning for load demand time series forecasting[J]. Applied Soft Computing, 2017, 54: 246-255.
- [34] Zahai Gao, Cunhao Ma, Dong Song, et al. Deep quantum inspired neural network with application to aircraft fuel system fault diagnosis[J]. Neurocomputing, 2017, 238: 13-23.
- [35] Peng H-K, Marculescu R. Multi-scale compositionality: Identifying the compositional structures of social dynamics using deep learning[J]. PLOS one, 2015, 10(4): e0118309.
- [36] ZhiQiang Chen, Chuan Li, Rene-Vinicio Sanchez. Gearbox fault identification and classification with convolutional neural networks[J]. Shock and Vibration, 2015, 390134.
- [37] Olivier Janssens, Viktor Slavkovikj, Bram Vervisch, et al. Convolutional neural network based fault detection for rotating machinery[J]. J of Sound and Vibration, 2016, 337: 331-345.
- [38] Mohammed Alawad, Mingjie Lin. Stochastic-based deep convolutional networks with reconfigurable logic fabric[J]. IEEE Trans on Multi-Scale Computing Systems, 2016, 2(4): 242-256.
- [39] 魏东, 龚庆武, 来文青, 等. 基于卷积神经网络的输电线路区内外故障判断及故障选相方法研究[J]. 中国电机工程学报, 2016, 36: 21-28.
(Wei D, Gong Q W, Lai W Q, et al. Research on internal and external fault diagnosis and fault-selection of transmission line based on convolutional neural network[J]. Proc of the Chinese Society for Electrical Engineering, 2016, 36: 21-28.)
- [40] Kai Wang, Youjin Zhao, Qingyu Xiong, et al. Research on healthy anomaly detection model based on deep learning from multiple time-series physiological signals[J]. Scientific Programming, 2016, 5642856.
- [41] Xiaojie Guo, Liang Chen, Changqing Shen. Hierarchical adaptive deep convolution neural network and its application to bearing fault diagnosis[J]. Measurement, 2016, 93: 490-502.
- [42] Haedong Jeong, Seungtae Park, Sunhee Woo, et al. Rotating machinery diagnostics using deep learning on orbit plot images[J]. Procedia Manufacturing, 2016, 5: 1107-1118.
- [43] Chen Lu, Zhenya Wang, Bo Zhou. Intelligent fault diagnosis of rolling bearing using hierarchical convolutional network based health state classification[J]. Advanced Engineering Informatics, 2017, 32: 139-151.
- [44] Junhua Sun, Zhongwen Xiao, Yanxia Xie. Automatic multi-fault recognition in TFDS based on convolutional neural network[J]. Neurocomputing, 2017, 222: 127-136.
- [45] Guojin Liu, Zhenzhi Yin, Yunjian Jia, et al. Passenger flow estimation based on convolutional neural network in public transportation system[J]. Knowledge-Based Systems, 2017: 1-14.
- [46] 邱立达, 刘天健, 林南, 等. 基于深度学习模型的无线传感器网络数据融合算法[J]. 传感技术学报, 2014, 27(12): 1704-1709.
(Qiu L D, Liu T J, Lin N, et al. Data aggregation in wireless sensor network based on deep learning model[J]. Chinese J of Sensors and Actuators, 2014, 27(12): 1704-1709.)
- [47] Martin Langkvist, Lars Karlsson, Amy Loutfi. A review of unsupervised feature learning and deep learning for time-series modeling[J]. Pattern Recognition Letters, 2014, 42(1): 11-24.
- [48] Demetgul M, Yildiz K, Tashin S, et al. Fault diagnosis on material handling system using feature selection and data mining techniques[J]. Measurement, 2014, 55(9): 15-24.
- [49] 苗中华, 周广兴, 刘海宁, 等. 基于稀疏编码的振动信号特征提取算法与实验研究[J]. 振动与冲击, 2014, 33(15): 76-81.
(Miao Z H, Zhou G X, Liu H N, et al. Tests and feature extraction algorithm of vibration signals based on sparse coding[J]. J of Vibration and Shock, 2014, 33(15): 76-81.)
- [50] 俞啸, 丁恩杰, 陈春旭, 等. 基于HHT和有监督稀疏编码的滚动轴承故障状态识别方法[J]. 煤炭学报, 2015, 40(11): 2587-2595.
(Yu X, Ding E J, Chen C X, et al. Rolling bearing fault state recognition method based on HHT and supervised Sparse Coding[J]. J of China Society, 2015, 40(11):

- 2587-2595.)
- [51] 庞荣, 于志斌, 熊维毅, 等. 基于深度学习的高速列车转向架故障识别[J]. 铁道科学与工程学报, 2015, 12(6): 1283-1288.
(Pang R, Yu Z B, Xiong W Y, et al. Faults recognition of high-speed train bogie based on deep learning[J]. J of Railway Science and Engineering, 2015, 12(6): 1283-1288.)
- [52] Utkin L V, Zaborovskii V S, Popov S G. Detection of anomalous behavior in a robot system based on deep learning elements[J]. Automatic Control and Computer Sciences, 2016, 50(8): 726-733.
- [53] Yihui Xiong, Renguang Zuo. Recognition of geochemical anomalies using a deep autoencoder network[J]. Computers & Geosciences, 2016, 86(C): 75-82.
- [54] Jiewu Leng, Pingyu Jiang. A deep learning approach for relationship extraction from interaction context in social manufacturing paradigm[J]. Knowledge-Based Systems, 2016, 100(C): 188-199.
- [55] 温博文, 董文瀚, 解武杰, 等. 深度自编码观测器飞机操纵面快速故障诊断[J]. 飞行力学, 2016, 34(6): 34-44.
(Wen B W, Dong W H, Xie W J, et al. Fast fault diagnostic method for aircraft actuators with deep auto-encoder observer[J]. Flight Dynamics, 2016, 34(6): 34-44.)
- [56] Wenjun Sun, Siyu Shao, Rui Zhao, et al. A sparse auto-encoder-based deep neural network approach for induction motor faults classification[J]. Measurement, 2016, 89: 171-178.
- [57] Shan Pang, Xinyi Yang, Xiaofeng Zhang. Aero engine component fault diagnosis using multi-hidden-layer extreme learning machine with optimized structure[J]. Int J of Aerospace Engineering, 2016, 1329561.
- [58] Ahmad Shaheryar, Xucheng Yin, Hong-Wei Hao, et al. A de-noising based auto-associative model for robust sensor monitoring in nuclear power plants[J]. Science and Technology of Nuclear Installations, 2016, 9746948.
- [59] Zhixin Yang, Xiaobo Wang, Jian-hua Zhong. Representational learning for fault diagnosis of wind turbine equipment: A multi-layered extreme learning machines Approach[J]. Energies, 2016, 9060379.
- [60] Hongmei Liu, Lianfeng Li, Jian Ma. Rolling bearing fault diagnosis based on STFT-deep learning and sound signals[J]. Shock and Vibration, 2016, 6127479.
- [61] Lukun Wang, Xiaoying Zhao, Jiangnan Pei, et al. Transformer fault diagnosis using continuous sparse autoencoder[J]. Springer Plus, 2016, 5(1): 448.
- [62] 孙文珺, 邵思羽, 严如强. 基于稀疏自动编码深度神经网络的感应电动机故障诊断[J]. 机械工程学报, 2016, 52(9): 65-71.
(Sun W J, Shao S Y, Yan R Q. Induction motor fault diagnosis based on deep neural network of sparse auto-encoder[J]. J of Mechanical Engineering, 2016, 52(9): 65-71.)
- [63] Chen Lu, Zhenya Wang, Wei-li Qin, et al. Fault diagnosis of rotary machinery components using a stacked de-noising auto-encoder-based health state identification[J]. Signal Processing, 2017, 130: 377-388.
- [64] Haidong Shao, Hongkai Jiang, Fuan Wang, et al. An enhancement deep feature fusion method for rotating machinery fault diagnosis[J]. Knowledge-Based System, 2017, 119: 200-220.
- [65] Hoyeop Lee, Youngju Kim, Chang Quk Kim. A deep learning model for robust wafer fault monitoring with sensor measurement noise[J]. IEEE Trans on Semiconductor Manufacturing, 2017, 30(1): 23-31.
- [66] 李鸿儒, 顾树生. 一种递归神经网络的快速并行算法[J]. 自动化学报, 2004, 30(4): 516-522.
(Li H R, Gu S S. A fast parallel algorithm for a recurrent neural network[J]. Acta Automatica Sinica, 2004, 30(4): 516-522.)
- [67] 陈如清. 两种基于神经网络的故障诊断方法[J]. 中国电机工程学报, 2005, 25(16): 112-115.
(Chen R Q. Comparison between two fault diagnosis methods based on neural network[J]. Proc of the Chinese Society for Electrical Engineering, 2005, 25(16): 112-115.)
- [68] Alexandre Evsukoff, Sylviane Gentil. Recurrent neuro-fuzzy system for fault detection and isolation in nuclear reactors[J]. Advanced Engineering Informatics, 2005, 19(1): 55-66.
- [69] Azzam I Moustapha, Rastko R Selmic. Wireless sensor network modeling using modified recurrent neural networks: Application to Fault Detection[J]. IEEE Trans on Instrumentation and Measurement, 2008, 57(5): 981-988.
- [70] Danil V Prokhorov. Toyota prius HEV neurocontrol and diagnostics[J]. Neural Networks, 2008, 21(2/3): 458-465.
- [71] 王旭红, 何怡刚. 基于对角递归神经网络的异步电动机定子绕组匝间故障诊断方法[J]. 电力自动化设备, 2009, 29(7): 60-63.
(Wang X H, He Y G. Inter-turn fault detection of asynchronous motor stator winding based on diagonal recurrent neural network[J]. Electric Power Automation Equipment, 2009, 29(7): 60-63.)
- [72] Li Shi, Lijia Wang, Zhizhong Wang. The modeling and the sensor fault diagnosis of a continuous stirred tank reactor with a takagi-sugeno recurrent fuzzy neural network[J]. Int J of Distributed Sensor Networks, 2009, 5(1): 37.
- [73] Talebi H A, Khorasani K, Tafazoli S, et al. A recurrent neural-network-based sensor and actuator fault detection and isolation for nonlinear systems with application to the satellite's attitude control subsystem[J]. IEEE Trans

- on Neural Network, 2009, 20(1): 45-60.
- [74] 汤宝平, 习建民, 李锋. 基于Elman神经网络的旋转机械故障诊断[J]. 计算机集成制造系统, 2010, 16(10): 2148-2152.
(Tang B P, Xi J M, Li F. Fault diagnosis of rotating machinery based on Elman neural network[J]. Computer Integrated Manufacturing Systems, 2010, 16(10): 2148-2152.)
- [75] Xiaoyu Wang, Yong Huang, Nhan Nguyen. Robustness quantification of recurrent neural network using unscented transform[J]. Neurocomputing, 2010, 74(1/2/3): 354-361.
- [76] Wu Yilei, Fuchun Sun, Jinchuan Zheng, et al. A robust training algorithm of discrete-time MIMO RNN and application in fault tolerant control of robotic systems[J]. Neural Computer & Applications, 2010, 19(7): 1013-1027.
- [77] 王晓霞, 马良玉, 王兵树, 等. 进化Elman神经网络在实时数据预测中的应用[J]. 电力自动化设备, 2011, 31(12): 77-81.
(Wang X X, Ma L Y, Wang B S, et al. Application of evolutionary Elman neural network in real-time data forecasting[J]. Electric Power Automation Equipment, 2011, 31(12): 77-81.)
- [78] 姜述强, 金鸿章, 魏凤梅. 可容错的遥控水下机器人递归神经网络控制[J]. 哈尔滨工业大学学报, 2013, 45(9): 57-63.
(Jiang S Q, Jin H Z, Wei F M. A fault-tolerable recurrent neural network controller for remote operated vehicle[J]. J of Harbin Institute of Technology, 2013, 45(9): 57-63.)
- [79] Banaei M R, Kami A. Interline power flow controller(IPFC) based damping recurrent neural network controllers for enhancing stability[J]. Energy Conversion and Management, 2011, 52(7): 2629-2636.
- [80] Talebi H A, Khorasani K. A neural network-based multiplicative actuator fault detection and isolation of nonlinear systems[J]. IEEE Trans on Control Systems Technology, 2013, 21(3): 842-851.
- [81] Oliver Obst. Distributed fault detection in sensor networks using a recurrent neural network[J]. Neural Processing Letters, 2014, 40(3): 261-273.
- [82] Pratik Roy, Mahapatra G S, Pooja Rani, et al. Robust feed-forward and recurrent neural network based dynamic weighted combination models for software reliability prediction[J]. Applied Soft Computing, 2014, 22(5): 629-637.
- [83] Nasser Talebi, Mohammad Ali Sadrnia, Ahmad Darabi. Robust fault detection of wing energy conversion systems based on dynamic neural networks[J]. Computational Intelligence and Neuroscience, 2014, 580972.
- [84] Pohjoranta A, Sorrentio M, Pianese C, et al. Validation of neural network-based fault diagnosis for multi-stack fuel cell systems: stack voltage deviation detection[J]. Energy Procedia, 2015, 81(173): 173-181.
- [85] Krzysztof Patan. Neural network-based model predictive control: Fault tolerance and stability[J]. IEEE Trans on Control Systems Technology, 2015, 23(3): 1147-1155.
- [86] Piotr Przysialka, Wojciech Moczulski. Methodology of neural modeling in fault detection with the use of chaos engineering[J]. Engineering Applications of Artificial Intelligence, 2015, 41(C): 25-40.
- [87] Mathiyalagan K, Anbuviya R, Sakthive R, et al. Reliable stabilization for memristor-based recurrent neural networks with time-varying delays[J]. Neurocomputing, 2015, 153: 140-147.
- [88] Faa-jeng Lin, I-fan Sun, Kai-jie Yang, et al. Recurrent fuzzy neural cerebellar model articulation network fault-tolerant control of six-phase permanent magnet synchronous motor position servo drive[J]. IEEE Trans on Fuzzy Systems, 2016, 24(1): 153-167.
- [89] Ahmad Mozaffari, Mahyar Vajedi, Nasser L Azad. A robust safety-oriented autonomous cruise control scheme for electric vehicles based on model predictive control and online sequential extreme learning machine with a hyper-level fault tolerance-based supervisor[J]. Neurocomputing, 2015, 151: 845-856.
- [90] Chih-Min Lin, Enkh-Amgalan Boldbaatar. Autolanding control using recurrent wavelet elman neural network[J]. IEEE Trans on Systems, Man, and Cybernetics: Systems, 2015, 45(9): 1281-1291.
- [91] Piero Baraldi, Francesco Di Maio, Davide Genini, et al. Comparison of data-driven reconstruction methods for fault detection[J]. IEEE Trans on Reliability, 2015, 64(3): 852-860.
- [92] Zeljko Deljac, Mirko Randic, Gordan Krcelic. A multivariate approach to predicting quantity of failures in broadband networks based on a recurrent neural network[J]. J of Network System and Management, 2016, 24(1): 189-221.
- [93] Amozegar M, Khorasani K. An ensemble of dynamic neural network identifiers for fault detection and isolation of gas turbine engines[J]. Neural Networks, 2016, 76: 106-121.
- [94] Marcin Mrugalski, Marcel Luzar, Marcin Pazera, et al. Neural network-based robust actuator fault diagnosis for a non-linear multi-tank system[J]. ISA Transactions, 2016, 61: 318-328.
- [95] Fan Yang, Hongli Dong, Zidong Wang, et al. A new approach to non-fragile state estimation for continuous neural networks with time-delays[J]. Neurocomputing, 2016, 197: 205-211.
- [96] Xu C, Wang G, Liu X G, et al. Health status assessment and failure prediction for hard drives with recurrent neural network[J]. IEEE Trans on Computers, 2016, 65(11):

- 3502-3508.
- [97] Tim de Bruin, Kim Verbert, Robert Babuska. Railway track circuit fault diagnosis using recurrent neural networks[J]. IEEE Trans on Neural Networks and Learning Systems, 2017, 28(3): 523-533.
- [98] 刘强, 秦泗钊. 过程工业大数据建模研究展望[J]. 自动化学报, 2016, 42(2): 161-171.
(Liu Q, Qin S Z. Perspectives on big data modeling of process industries[J]. Acta Automatica Sinica, 2016, 42(2): 161-171.)
- [99] 周东华, 史建涛, 何潇. 动态系统间歇故障诊断技术综述[J]. 自动化学报, 2014, 40(2): 161-171.
(Zhou D H, She J T, He X. Review of intermittent fault diagnosis techniques for dynamic systems[J]. Acta Automatica Sinica, 2014, 40(2): 161-171.)
- [100] Yanming Guo, Yu Liu, Ard oerlemans, et al. Deep learning for visual understanding: A review[J]. Neurocomputing, 2016, 187(C): 27-48.
- [101] Jurgen Schmidhuber. Deep learning in neural networks: An overview[J]. Neural Networks, 2015, 61: 85-117.
- [102] Weining Lu, Bin Liang, Yu Cheng, et al. Deep model based domain adaptation for fault diagnosis[J]. IEEE Trans on Industrial Electronics, 2017, 64(3): 2296-2305.
- [103] Nawel Bayar, Saber Darmoul, Sonia Hajri-Gabouj, et al. Fault detection, diagnosis and recovery using artificial immune systems: A review[J]. Engineering Applications of Artificial Intelligence, 2015, 46(PA): 43-57.
- [104] Matthew J Daigle, Indranil Roychoudhury, Gautam Biswas, et al. A comprehensive diagnosis methodology for complex hybrid systems: A case study on spacecraft power distribution systems[J]. IEEE Trans on Systems, Man, and Cybernetics-Part A: Systems and Humans, 2010, 40(5): 917-931.
- [105] Baoping Cai, Hanlin Liu, Min Xie. A real-time fault diagnosis methodology of complex systems using object-oriented Bayesian networks[J]. Mechanical CSys and Signal Processing, 2016, 80: 31-44.
- [106] Li Deng. A tutorial survey of architectures, algorithms, and applications for deep learning[J]. Apsipa Trans on Signal & Information Processing, 2014, 3: e2.
- [107] Heshan Fernando, Brian Surgenor. An unsupervised artificial neural network versus a rule-based approach for fault detection and identification in an automated assembly machine[J]. Robotics and Computer-Integrated Manufacturing, 2017, 43: 79-88.
- [108] Peng Jiang, Zhixin Hu, Jun Liu, et al. Fault diagnosis based on chemical sensor data with an active deep neural network[J]. Sensors, 2016, 16(10): 1695.
- [109] Mingbo Zhao, Xiaohang Jin, Zhao Zhang, et al. Fault diagnosis of rolling element bearings via discriminative subspace learning: Visualization and classification[J]. Expert Systems with Applications, 2014, 41(7): 3391-3401.
- [110] Wei Zheng, Desheng Hu, Jing Wang. Fault localization analysis based on deep neural network[J]. Mathematical Problems in Engineering, 2016, 1820454.
- [111] Wenchao Yu, Fuzhen Zhuang, Qing He, et al. Learning deep representations via extreme learning machines[J]. Neurocomputing, 2015, 149: 308-315.
- [112] Fikadu B Degefa, Donghooon Lee, Jiye Kim, et al. Performance and security enhanced authentication and key agreement protocol for SAE/LTE network[J]. Computer Networks, 2016, 94: 145-163.
- [113] Yushua Bengio, Aaron Courville, Pascal Vincent. Representation learning: A review and new perspectives[J]. IEEE Trans on Pattern Analysis and Machine Intelligence, 2013, 35(8): 1798-1828.
- [114] Takashi Kuremoto, Shinsuke Kimura, Kunikazu Kobayashi, et al. Time series forecasting using a deep belief network with restricted Boltzmann machines[J]. Neurocomputing, 2014, 137(5): 47-56.
- [115] Gao Huang, Guang-Bin Huang, Shiji Song, et al. Trends in extreme learning machines: A review[J]. Neural Networks, 2015(C), 61: 32-48.
- [116] 雷亚国, 贾峰, 周昕, 等. 基于深度学习理论的机械装备大数据监控监测方法[J]. 机械工程学报, 2015, 51(21): 49-56.
(Lei Y G, Jia F, Zhou X, et al. A deep learning-based method for machinery health monitoring with big data[J]. J of Mechanical Engineering, 2015, 51(21): 49-56.)
- [117] 李本威, 林学森, 杨欣毅, 等. 深度置信网络在发动机气路部件性能衰退故障诊断中的应用研究[J]. 推进技术, 2016, 37(11): 2173-2180.
(Li B W, Lin X S, Yang X Y, et al. Research on application of deep belief networks on engine gas path component performance degradation defect diagnostic[J]. J of Propulsion Technology, 2016, 37(11): 2173-2180.)
- [118] 潘广源, 柴伟, 乔俊飞. DBN网络的深度确定方法[J]. 控制与决策, 2015, 30(2): 256-260.
(Pan G Y, Chai W, Qiao J F. Calculation for depth of deep belief network[J]. Control and Decision, 2015, 30(2): 256-260.)
- [119] 张俊俊, 何良华. 动态深度信念网络模型构建[J]. 微型机与应用, 2017, 36(1): 59-65.
(Zhang J J, He L H. Construction of dynamic deep belief network model[J]. Microcomputer its Application, 2017, 36(1): 59-65.)
- [120] Cheng-Yuan Liou, Wei-Chen Cheng, Jiun-Wei Liou, et al. Autoencoder for words[J]. Neurocomputing, 2014, 139: 84-96.